

프로젝트 제안서 (2 조)

흥행 영화의 특징은 무엇인가?

TMDB 데이터 기반 흥행 결정 요인 분석 및 제작 전략 제안

pm:20201337 김범수

en:20222114 신진협

an:20243718 김혜빈

1. 소개

1.1 배경

영화 산업은 막대한 제작비와 마케팅 비용이 투입되는 고위험 산업이다. 전 세계 박스오피스 규모는 연간 수십조 원에 달하지만, 개봉 영화의 상당수는 손익분기점을 넘지 못하고 흥행에 실패한다. 영화의 흥행 여부는 단순히 작품의 질만으로 결정되는 것이 아니라, 예산 규모, 장르 선택, 감독 및 출연진, 개봉 시기 등 다양한 변수의 복합적인 상호작용에 의해 결정된다.

이러한 복잡한 구조로 인해 영화 제작 및 투자 의사결정은 높은 불확실성을 가지며, 이를 정량적으로 분석하려는 필요성이 증가하고 있다. 데이터 분석 기반의 접근은 이러한 의사결정을 보다 객관적으로 지원할 수 있는 중요한 도구로 주목받고 있다.

본 프로젝트는 TMDB(The Movie Database) 오픈 데이터를 활용하여 영화 흥행에 영향을 미치는 핵심 변수를 분석하고, 수익 예측 모델을 구축하는 것을 목표로 한다.

1.2 문제 제기

하지만 현재 영화 산업에서는 데이터 기반 의사결정이 충분히 이루어지지 못하고 있다는 한계가 존재한다.

첫째, 어떤 장르 조합, 예산 규모, 감독 및 출연진 특성이 흥행에 유리한지에 대한 정량적 분석이 부족하다.

둘째, 영화 흥행은 다양한 요인의 복합적인 상호작용에 의해 결정되지만, 이를 동시에 고려하는 체계적인 분석 방법이 제한적이다.

셋째, 기존 의사결정은 경험적 직관이나 유사 사례에 의존하는 경우가 많아, 객관성과 일반화 가능성이 낮다.

따라서 본 프로젝트에서는 다양한 영화 특성을 동시에 고려한 데이터 마이닝 기법을 적용하여, 흥행에 영향을 미치는 주요 요인을 도출하고 수익 예측 가능성을 분석하고자 한다.

1.3 가설

- 제작 예산이 높을수록 흥행 수익(revenue)이 높을 것이다. → 예산-수익 간 상관계수로 검증
- 특정 장르 조합(예: 액션+어드벤처)은 수익과 유의미한 상관관계를 가질 것이다. → 장르별 원-핫 인코딩 후 상관분석으로 검증
- PCA 를 적용하면 영화 데이터의 주요 특성을 소수의 주성분으로 요약할 수 있을 것이다.
- 선형 회귀 모델과 랜덤 포레스트 회귀 모델을 활용하여 수익 예측 성능을 평가하고 비교한다. → Train/Test 분할 후 RMSE, R^2 , MAE 를 기준으로 모델 성능을 평가할 것이다.

1.4 목표

- TMDb Movies Daily Updates Dataset 을 활용하여 흥행 결정 변수를 탐색·분석한다.
- PCA 를 통해 고차원 특성을 압축하고 시각적 패턴을 확인한다.
- 선형 회귀 및 트리 기반 모델로 수익 예측 모델을 구축하고 성능을 비교한다.
- 분석 결과를 바탕으로 '흥행 가능성이 높은 영화의 조건'을 도출하고, 제작 및 투자 전략에 대한 인사이트를 제시한다.

2. 방법

2.1 데이터 설명

본 프로젝트는 Kaggle의 TMDb Movies Daily Updates Dataset을 사용한다. 해당 데이터셋은 영화의 제작 정보(예산), 콘텐츠 정보(장르, 출연진), 그리고 성과 지표(수익, 평점 등)를 포함하고 있으며, 각 행은 하나의 영화 데이터를 의미한다

▶ 유지 칼럼

budget: 영화 제작 비용으로, 수익과의 관계 분석을 위한 핵심 변수

revenue: 영화 흥행 수익으로, 본 프로젝트의 타겟 변수

genres: 영화 장르 정보로, 장르별 흥행 특성을 분석하기 위해 활용

popularity: 영화 인기도 지표로, 흥행과의 관련성을 확인하기 위해 활용

vote_average, vote_count: 영화에 대한 평균 평점과 참여 수로, 대중의 평가와 관심도를 반영

하는 변수

runtime: 상영시간으로, 영화 길이와 흥행 간 관계를 확인하기 위해 활용

release_date: 개봉일 정보로, 연도 및 월 파생 변수를 생성하여 시기적 특성을 분석하는 데 활용

original_language: 영화 원어 정보로, 언어권에 따른 흥행 차이를 보조적으로 확인하기 위해 활용

director: 감독 정보로, 감독별 흥행 특성을 반영하기 위해 활용

cast: 출연진 정보로, 주요 배우의 참여 여부가 흥행에 미치는 영향을 확인하기 위해 활용

imdb_rating, imdb_votes: IMDb 평점 및 참여 수로, 외부 평가 지표와 대중 반응을 반영하는 변수

▶ 제거 칼럼

id, imdb_id: 단순 식별자이므로 분석에 불필요

title, original_title: 텍스트 식별 정보로, 본 연구의 수치 기반 분석 범위에서는 직접 활용이 어려움

overview, tagline: 비정형 텍스트 데이터로, 추가적인 자연어 처리 과정이 필요하므로 이번 분석 범위에서는 제외

status: 값의 다양성이 크지 않을 가능성이 있어 정보 가치가 낮다고 판단하여 제외

poster_path: 이미지 경로 정보로, 예측과 직접적인 관련성이 낮아 제외

production_companies, production_countries, spoken_languages: 범주 수가 많고 다중값 구조를 가져 전처리 부담이 크므로 이번 프로젝트에서는 제외

director_of_photography, writers, producers, music_composer: 의미 있는 정보일 수 있으나 범주 다양성이 높고 분석 범위가 과도하게 확장될 수 있어 제외

▶ 전처리 계획

release_date → 연도(year), 월(month) 파생 변수 생성

genres → 다중값 구조 → 원-핫 인코딩 처리

director / cast → 빈도 기반으로 주요 인물만 변수화

결측치 제거 및 이상치(budget, revenue) 필터링

필요 시 revenue 로그 변환 적용

2.2 모델 선정 이유

- 상관분석: 변수-수익 관계 탐색 첫번째 두 번째 가설 검증에 직결
- PCA: 고차원 특성 압축 및 시각화 장르·키워드 원-핫 인코딩 후 차원 축소, 또한 이는 예측 모델이 아닌 데이터 구조 파악을 위한 차원 축소 기법으로써 활용.
- 선형회귀(Linear Regression): 수익 예측 기준 모델 변수와 수익 간의 관계를 기반으로 예측이 가능하며, 결과 해석이 용이함
- 랜덤 포레스트 회귀: 영화 흥행 수익은 여러 변수 간의 복합적 상호작용과 비선형 관계에 의해 결정될 가능성이 크다고 판단하여 선정하였다. 이를 통해 비선형 패턴을 반영한 수익 예측이 가능하며, 선형 회귀 모델과의 성능 비교에도 활용할 수 있다.

2.3 분석 파이프라인

- 데이터 수집 및 탐색적 분석 (EDA): 결측치 확인 및 제거, 이상치 확인, 변수별 분포를 히스토그램과 박스플롯을 통해 시각화한다. release_date 를 연도(year), 월(month) 변수로 변환하고, genres 는 원-핫 인코딩 처리한다.
- 상관분석: 수치형 변수와 revenue 간 상관관계수 계산 및 히트맵 시각화
- PCA: 수치형 변수를 표준화한 후 PCA 를 적용하고, 설명 분산 비율을 통해 주요 주성분을 확인한다.
또한 2 차원 시각화를 통해 데이터의 전반적인 분포와 패턴을 파악한다.
- 모델 학습: 전처리된 데이터를 기반으로 Train / Test 분할 (8:2 비율)을 수행하고, 선형 회귀 및 랜덤 포레스트 모델을 학습하여 RMSE, MAE, R^2 를 기준으로 성능을 평가한다.

2.4 파라미터 설정 계획

본 프로젝트에서 사용하는 분석 기법 중 선형 회귀와 상관분석은 별도의 주요 하이퍼파라미터 설정 없이, PCA는 진행 과정 중 주성분개수를 결정하며 랜덤 포레스트는 초기 하이퍼파라미터는 아래와 같이 설정하며, 검증 성능에 따라 조정할 예정이다.

- n_estimators: 모델 학습에 사용될 결정 트리의 개수 (초기값: 100, 200)
- max_depth: 트리의 최대 깊이로, 모델의 복잡도와 과적합을 제어 (초기값: None, 10, 20)
- min_samples_split: 노드를 분할하기 위해 필요한 최소 샘플 수 (초기값: 2)
- random_state: 실험 결과의 재현성을 확보하기 위한 난수 생성 시드 (특정 숫자 고정)

3. 예상 결과

3.1 평가 지표

본 프로젝트는 연속형 변수인 영화 수익을 예측하는 것을 목표로 하므로 모델의 예측 정확도를 다양한 관점에서 평가하기 위해 아래의 지표를 사용한다.

- RMSE: 실제 수익 단위 기준으로 오차 크기를 직관적으로 파악 가능하며, 큰 오차에 더 민감하여 주요 예측 오류를 반영한다.
- R^2 : 모델이 수익 변동을 얼마나 설명하는지를 나타내는 지표로, 모델 간 성능 비교에 활용한다.
- MAE: 절대 오차 평균으로, 이상치의 영향을 덜 받아 모델의 안정성을 보완적으로 평가한다.

3.2 예상 결과

- 상관분석: budget 과 revenue 간에는 양의 상관관계가 나타날 것으로 예상된다. 액션.어드벤처 장르 변수에서도 유의미한 정적 상관이 관찰될 것으로 보인다.
- PCA: 여러 변수로 구성된 고차원 데이터를 소수의 주성분으로 축소할 수 있을 것으로 예상되며,이를 통해 영화 데이터의 주요 패턴을 시각적으로 확인할 수 있을 것이다.
- 회귀 모델: 선형 회귀 모델을 기준으로 일정 수준의 예측성능이 나타날 것으로 예상되며, 랜덤 포레스트 회귀 모델은 비선형 관계를 반영하여 더 높은 예측 성능을 보일 것으로 예상된다.
- 분석결과를 바탕으로 예산, 장르, 평점등의 주요 변수가 영화 수익에 영향을 미치는 요인으로 예상되며 이를 통해 흥행 가능성이 높은 영화의 특성을 정리하고 제작 및 투자 전략에 대한 인사이트를 제시할 수 있을 것으로 예상된다.

4. 기대효과

4.1 실용적 기대효과

- 영화 제작사 및 투자자는 기획 단계에서 예산.장르.감독 조합의 흥행 가능성을 수치 기반으로 사전 검토할 수 있다.
- 스트리밍 플랫폼(넷플릭스, 웨이브 등)의 콘텐츠 투자 및 기획 전략 수립에 데이터 기반 분석 방법을 적용할 수 있다.

- 분석결과를 통해 흥행 영화와 비흥행 영화의 주요 특성을 파악하고, 신규 콘텐츠 기획 시 참고할 수 있는 기준을 제공할 수 있다.

4.2 학문적 기대효과

- 수업에서 학습한 상관분석, PCA, 회귀 이론을 실제 대규모 데이터에 적용하여 이론과 실습을 연계한다.
- 선형 모델과 앙상블 모델의 성능 비교를 통해 각 모델의 특성과 한계를 실증적으로 파악한다.
- 데이터 전처리, 탐색적 분석, 모델 적용 및 결과 해석 과정을 수행함으로써 데이터 마이닝에 대한 전반적인 이해도를 향상시킬 수 있다.